

의미·빈도 정보를 반영한 로그 복합 임베딩 기반 이상 탐지 기법

Semantic and Frequency-Aware Hybrid Log Embedding for Anomaly Detection



김예은⁰¹, 구본유², 한인성³, 이정식³, 박성진⁴, 임선영⁴, 오병국²

¹건국대학교 스마트ICT융합공학과, ²건국대학교 컴퓨터공학과, ³국방과학연구소, ⁴LIG Defence & Aerospace

{katekim512, bykoo, bkoh}@konkuk.ac.kr, p9741181@gmail.com, godsider@naver.com, {sungjin.park2, sunyoung.im}@ligdna.com




Paper



Background

Motivation

- 실무자의 95.5% 이상이 자동 로그 이상 탐지가 필수(Essential) 또는 가치 있음(Worthwhile)이라고 응답할 만큼 대규모 시스템의 안정적인 운영을 위한 로그 이상 탐지의 중요성이 강조되고 있음



Source : Practitioners' Expectations on Log Anomaly Detection(2024)

Existing Approaches


- DeepLog[2]는 LSTM 기반의 순환 신경망을 활용하여 로그의 순차적인 흐름을 학습
- LogBERT[1]에서는 Drain 등의 파서를 통해 원시 로그(Raw log)를 템플릿으로 변환 후 시퀀스로 입력
- 이벤트를 랜덤 임베딩으로 표현, 로그 시퀀스의 순차적 패턴 학습에 국한

Challenges

- 로그 템플릿화로 인한 파라미터, 경로, 수치 등 세부 정보 손실
- 의미가 유사한 로그 간 관계 반영 불가
- 특정 이벤트가 급증하는 로그 폭풍(Log Storm) 같은 양적 이상 패턴 포착 어려움

Contribution

Random vs Semantic and Frequency-Aware Embedding




Event Template의 거시적 의미, 원시 로그의 세부 의미, 발생 빈도의 양적 변화를 독립적으로 임베딩한 뒤 결합하는 **새로운 로그 임베딩 방식 제안**

- 기존 로그 파싱 과정의 정보 손실과 랜덤 임베딩의 의미적 한계를 보완하여 의미·양적 정보를 동시에 반영
- HDFS, BGL, Tbird 데이터셋에서 기존 LogBERT 대비 이상 탐지 성능 향상 확인
- 데이터셋 특성에 따른 각 임베딩의 기여도 분석

Experiments

- 제안한 임베딩 방식은 BGL과 Tbird 데이터셋에서 가장 높은 성능을 기록


Method	HDFS	BGL	TBird
LogBERT + rand (Baseline)	73.531	40.997	87.790
LogBERT + v_f	74.797	55.393	87.733
LogBERT + v_e	79.223	60.077	87.883
LogBERT + $v_e + v_f$	75.040	60.257	88.647
LogBERT + $v_s + v_e + v_f$ (Proposed)	77.037	61.797	90.393



- 특히 BGL에서는 기존 대비 약 20 이상의 성능 향상
 - 로그의 의미 정보와 발생 빈도를 함께 반영하는 것이 이상 탐지에 효과적
- Frequency Embedding은 LogStorm 환경에서 큰 성능 향상을 보임
 - BGL 데이터셋에서 단독 추가만으로 14.4 향상
- SemanticID Embedding 결합 시 대부분 데이터셋에서 성능 증가
 - 기존 파서가 제거했던 원시 로그의 세부 의미 정보를 학습에 반영
- 정형화된 구조를 가진 데이터셋(HDFS)에서는 Event Template Embedding 만으로도 높은 성능 달성
 - HDFS는 11M개의 로그에도 불구하고 템플릿 수가 단 20개에 불과

Proposed Method

Semantic and Frequency-Aware Hybrid Log Embedding



Step 1. 서로 다른 관점에서의 Embedding

① Event Template Embedding

- 파서를 통해 추출된 이벤트 템플릿을 Sentence-BERT[3]로 임베딩
- 무작위 초기화 방식과 달리, 유사한 의미의 템플릿 간 의미적 상관관계를 수치화
- 로그 시퀀스의 거시적 흐름과 문맥적 의미를 파악
- 유사한 기능을 수행하는 템플릿 간 연관성을 LogBERT에 전달

② Frequency Embedding

- RLE(Run-Length Encoding)를 적용해 동일 이벤트의 연속 발생 횟수 추출
 - (예시) 시퀀스 [1,1,2,2,3] -> 빈도 시퀀스 [2,2,2,2,1]
- 추출된 빈도 값을 MLP (Multi-Layer Perceptron)로 학습 가능한 벡터로 변환
- 로그의 양적 패턴(로그 폭풍 등)을 반영하는 표현으로 사용

③ SemanticID Embedding

- 원시 로그 텍스트 전체를 Sentence-BERT[3]로 임베딩
- 계층적 잔차 양자화(Residual Quantization)로 이산화된 Semantic ID 생성 (Codebook 기반)
- 각 단계 코드북은 의미 공간을 대표하는 기준 벡터를 보유, 입력 벡터와 유클리드 거리가 가장 가까운 인덱스를 순차 할당
- 생성된 Semantic ID를 MLP로 학습 가능한 임베딩 벡터로 변환하여 파서가 제거한 세부 정보를 벡터 공간에 보존

Step 2. Embedding Fusion

- 세 가지 임베딩 (Event Template, Frequency, Semantic ID)을 동일한 차원으로 구성
- 원소별 덧셈(Element-wise Addition) 방식으로 결합 → 차원 팽창 없이 서로 다른 관점의 정보를 단일 벡터에 중첩, 이후 LogBERT[2]에 입력

Future Works

- 데이터셋의 특성을 반영하여 각 임베딩의 기여도를 동적으로 조절하는 방식을 통해 다양한 로그 환경으로 확장
- 실제 환경에 대한 검증을 통해 일반화 성능을 분석

References

- [1] Haixuan Guo, Shuhan Yuan, and Xintao Wu. "LogBERT : Log Anomaly Detection via BERT ", 2021
- [2] Min Du, Feifei Li, Guineng Zheng, and Vivek Srikumar. "DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning." Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS), pp. 1285-1298 , 2017.
- [3] Nils Reimers and Iryna Gurevych. "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks." Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 3982-3992, 2019.