




멀티모달 의미 확장 기반의 해석 가능한 계층적 Textual ID 생성 기법



사예원¹, 구해윤¹, 한인성², 이정식², 박성진³, 임선영³, 오병국¹

¹건국대학교 컴퓨터공학부, ²국방과학연구소, ³LIG Defence & Aerospace

{bear100152, hykoo0601, p9741181}@gmail.com, godsider@naver.com, {sungjin.park2, sunyoung.im}@ligdna.com, bkoh@konkuk.ac.kr

Motivation

기존 접근법

- 추천 시스템은 주로 사용자-아이템 상호작용을 기반으로 아이템을 dense embedding으로 표현함
- 텍스트, 이미지 등 다양한 모달리티를 활용한 멀티모달 추천 연구가 진행되고 있음
- GRAM, CARD와 같은 최근 연구는 semantic ID 또는 계층적 token을 활용하여 아이템 표현을 구조화하고자 함

한계 및 문제점

- 기존 아이템 표현은 dense embedding 또는 semantic ID에 의존하여 사람이 의미를 직접 해석하기 어려움
- 멀티모달 정보를 활용하더라도 단순 결합에 머무르는 경우가 많아, 아이템 간 구조적 의미와 해석 가능성을 충분히 반영하지 못함

Contribution

- 이미지 캡션과 아이템 텍스트를 결합한 멀티모달 의미 확장 방식 제안
- 아이템 간 의미적·시각적 관계를 반영하는 **그래프 기반 계층적 클러스터링 적용**
- 사람이 **해석 가능한 hierarchical textual ID를 생성**하고, GRAM 및 CARD 대비 계층 구조 품질과 해석 가능성 향상을 확인

Experiments

평가 지표

- Purity / NMI: 생성된 계층 구조의 카테고리 일관성·품질 평가
- TMR: textual ID 토큰이 원본 텍스트에 포함되는 비율
- CA: textual ID 토큰과 실제 카테고리 간 의미 일치도

Main Result

Metric	Ours	CARD	GRAM
Purity@L1	0.9976	0.7955	0.8584
Purity@L2	0.9978	0.9634	0.9476
Purity@L3	0.9989	0.9981	0.9812
NMI@L1	0.5184	0.5160	0.6464
NMI@L2	0.9886	0.6442	0.6420
NMI@L3	0.6969	0.6533	0.6486

→ Ours는 모든 Purity 지표와 NMI@L2, NMI@L3에서 가장 높은 성능을 보임

Interpretability

Metric	Ours	GRAM
TMR-title	0.2489	0.0273
TMR-meta	0.4622	0.0297
CA@Top1	0.2569	0.0004
CA@Top2	0.6247	0.0045

→ Ours는 GRAM 대비 TMR과 CA가 크게 높아 textual ID가 원본 텍스트 및 실제 카테고리 의미를 더 잘 반영함


Computational Complexity

방법	시간 복잡도	주요 병목
GRAM	$O(Nd + LNCd)$	계층적 클러스터링
CARD	$O(Nd + NqKd)$	codebook 할당
Ours	$O(Nd + N^2d + LNCd)$	아이템 유사도 그래프 구축

→ Ours는 아이템 유사도 그래프 구축의 $O(N^2d)$ 가 주요 병목이나, 이는 오프라인 textual ID 생성 단계에서 수행됨

- 제안 방법은 GRAM 및 CARD 대비 높은 계층 구조 품질을 보였으며, GRAM 대비 textual ID 해석 가능성에서도 우수한 성능을 확인

Proposed Method



① 멀티모달 의미 정보 확장

- 상품 이미지를 BLIP 기반 캡션 모델로 텍스트화하고, 이를 기존 title, brand, description 메타데이터와 결합하여 enriched text를 구성

→ 이를 통해 기존 텍스트 정보만으로 포착하기 어려운 색상, 형태, 스타일 등 **시각적 의미**를 **아이템 표현에 반영**

② 멀티모달 아이템 그래프 구축

- 각 아이템을 하나의 노드로 정의하고, SBERT 기반 텍스트 임베딩과 CLIP 기반 이미지 임베딩을 결합하여 노드 특성 구성
- 결합된 멀티모달 표현 간 코사인 유사도를 계산하고, 각 아이템의 상위 k개 이웃을 연결하여 kNN 기반 아이템 그래프 구축

→ 사용자-아이템 co-interaction 관계를 추가로 반영하여 의미적 유사성뿐 아니라 **상호작용 기반 관계까지 포함**

③ 그래프 기반 아이템 클러스터링

- 구축된 멀티모달 아이템 그래프에 spectral clustering을 적용하여 **그래프 구조가 반영된 spectral embedding**을 생성
- 이후 k-means를 재귀적으로 적용하여 **coarse-to-fine 방식의 계층 클러스터 구조를 형성**

④ 계층적 의미 인덱싱(HSI)

- 각 아이템을 coarse-to-fine 클러스터 경로로 표현하여 계층적 구조를 부여
- 각 계층의 클러스터별로 소속 아이템의 enriched text를 통합하고, **TF-IDF 기반 대표 토큰을 추출**

→ 계층별 대표 토큰을 순서대로 결합하여 아이템의 의미 구조를 반영하는 textual ID를 생성

Reference

- [1] Lee et al., "GRAM: Generative Recommendation via Semantic-aware Multi-granular Late Fusion", WWW, 2024.
- [2] Wei et al., "CARD: Non-Uniform Quantization of Visual Semantic Unit for Generative Recommendation", SIGIR, 2026.
- [3] Radford et al., "Learning Transferable Visual Models From Natural Language Supervision", ICML, 2021.
- [4] Li et al., "BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation", ICML, 2022.